

“گزارش فاز دوم پروژه”

صفحه مشخصات پروژه

نام و نام خانوادگی : سپیده پاشایان

شماره دانشجویی : 402103242

نسخه پایتون و کتابخانه‌های استفاده شده : Python 3.x, Pandas, Numpy, Scikit-learn, Matplotlib, Seaborn

مقدمه و هدف گزارش

هدف کلی

پیش‌بینی ریسک بیماری قلبی بر اساس داده‌های کلینیکی و پارامترهای آزمایشگاهی بیماران.

خروجی نهایی

دستیابی به مدلی با دقت (Accuracy) حدود ۸۹٪ که بتواند به پزشکان در تشخیص سریع کمک کند

معرفی دیتاست اولیه

تعداد رکوردها

۲۰۰۴۰ سطر و ۲۶ ستون.

نوع داده‌ها

ترکیبی از داده‌های عددی (Age, BMI, Troponin) ، طبقه‌ای (Hospital, Arrhythmia) و باینری (Sex, Target).

ستون Target

دارای دو مقدار ۰ (کمخطر) و ۱ (پرخطر) است

رویکرد کلی شما در پیش پردازش

منطق من در این پروژه بر سه اصل استوار بود

یکپارچه سازی

تبدیل تمام مقادیر متنی (فارسی و انگلیسی) به فرمت عددی

دقت علمی

محاسبه BMI به جای پر کردن ساده آن

کاهش پیچیدگی

ادغام دسته های مشابه (مثل حروف کوچک و بزرگ).

تحلیل، تشخیص مشکل و پیش پردازش داده ها

مدیریت مقادیر مفقود

تشخیص مشکل

ستون های BMI ، Diabetes و Smoking دارای مقادیر خالی بودند.

تصمیم گیری

برای BMI از فرمول وزن تقسیم بر قد به توان ۲ استفاده شد. برای بقیه از مقدار مد (Mode) استفاده کردیم.

```
df_clean['BMI'] = df_clean['BMI'].fillna(df_clean['Weight'] / ((df_clean['Height'] / 100) ** 2))
```

```
df_clean['Diabetes'] = df_clean['Diabetes'].fillna(df_clean['Diabetes'].mode()[0])
```

استانداردسازی داده‌های متنی و فارسی

تشخیص مشکل

در ستون‌هایی مثل Heart_Failure یا Sex مقادیر به صورت 'بله'، 'خیر'، 'M' و 'F' پراکنده بودند.

تصمیم‌گیری

تمام مقادیر به ۰ و ۱ (Map) شدند تا برای مدل قابل فهم باشند

```
df_clean['Heart_Failure'] = df_clean['Heart_Failure'].replace({'True': 1, 'False': 0, 'بله': 1, 'خیر': 0, 'no': 0})
```

مهندسی ویژگی‌های زمانی

تشخیص مشکل

تاریخ‌های ورود و خروج به صورت رشته (String) بودند و مدل نمی‌توانست آن‌ها را پردازش کند.

تصمیم‌گیری

ستون جدیدی به نام FollowUp_Period ایجاد شد که فاصله بین دو تاریخ را به تعداد روز نشان می‌دهد

```
df_clean['FollowUp_Period'] = (df_clean['Last_Visit_Date'] - df_clean['Admission_Date']).dt.days
```

بررسی نهایی دیتاست پس از پیش‌پردازش

توصیف وضعیت نهایی

پس از اتمام مراحل پیش‌پردازش، تمامی ستون‌های دیتاست از نوع عددی `int` یا `float` هستند. مقادیر مفقود به طور کامل مدیریت شده و هیچ مقدار تهی در مجموعه داده باقی نمانده است.

خلاصه تغییرات

تعداد ویژگی‌ها

تعداد ستون‌ها به دلیل استفاده از `get_dummies` برای متغیرهای کتگوریکال (مثل بیمارستان و نوع آریتمی) افزایش یافت تا مدل بتواند تفاوت میان آن‌ها را درک کند.

یکپارچگی

ستون `Target` به عنوان خروجی نهایی، توازن مناسبی دارد و سایر ویژگی‌ها بر اساس آن توزیع شده‌اند.

بررسی نهایی (کد و خروجی)

با اجرای دستور `data_final.isnull().sum().sum()` عدد ۰ حاصل شد که نشان‌دهنده پاکسازی ۱۰۰ درصدی داده‌هاست.

نمودار نهایی

نمودار **Heatmap** همبستگی (`Correlation`) نشان می‌دهد چگونه متغیرهایی مثل تروپونین بیشترین همبستگی را با `Target` پیدا کرده‌اند.

جمع‌بندی نهایی

پروژه با موفقیت توانست داده‌های خام و نامنظم بیمارستانی را به یک مدل پیش‌بینی دقیق تبدیل کند.

استفاده از مهندسی ویژگی‌ها و پاکسازی دقیق زبان فارسی نقش کلیدی در رسیدن به دقت ۸۹٪ داشت.

مدل نهایی نشان داد که فاکتورهای آزمایشگاهی مانند تروپونین و رفتاری مانند مصرف الکل و سیگار، بیشترین وزن را در ریسک بیماری قلبی دارند

بخش مدل‌سازی و خروجی نهایی

پارامترهای مدل

`max_depth=4 , random_state=2`

تحلیل خروجی:

دقت: ۸۹/۴۷٪

مهم‌ترین ویژگی: سطح تروپونین (Troponin Level) با حدود ۲۹٪ تأثیر، بیشترین نقش را در تشخیص مدل داشت.

ماتریس آشفتگی: نشان داد که مدل در تشخیص افراد سالم (Low Risk) بسیار عالی عمل می‌کند (Precision: 85%) و در تشخیص افراد بیمار نیز دقت ۹۹٪ دارد.

منابع

کتابخانه‌های تخصصی پایتون:

Pandas & Numpy

برای مدیریت ساختار داده‌ها و محاسبات ریاضی BMI و هندل کردن NaN

Scikit-learn

استفاده از ماژول‌های tree برای مدل‌سازی و preprocessing برای آماده‌سازی داده‌ها.

Matplotlib & Seaborn

جهت ترسیم نمودارهای تحلیلی و بصری‌سازی درخت تصمیم.

مستندات علمی و فنی

مستندات رسمی کتابخانه Scikit-learn برای تنظیم پارامترهای `max_depth` و `min_samples_split`.

استانداردهای پزشکی برای محاسبه شاخص توده بدنی (BMI) بر اساس قد و وزن.
دستورالعمل فاز دوم پروژه جهت رعایت محدودیت‌های مدل‌سازی.